

SKILLBRIDGE BIG DATA

Documentation Exhaustive : Écosystème Big Data, Conteneurs, Scripts & Commandes

Une plongée profonde dans l'architecture distribuée de SkillBridge. Ce rapport détaille exhaustivement chaque conteneur Docker, chaque fichier de configuration, l'ensemble des logiques MapReduce/HiveQL, l'ingestion temps réel Flume, le cache HBase, ainsi que les commandes de terminal pour les démonstrations interactives.

Auteur : Omar El Khali

Projet : SkillBridge - Plateforme E-Learning Intelligente

Date de Publication : 20 mai 2026

1. Architecture Docker & Rôle des Conteneurs

Le cluster Big Data de SkillBridge fonctionne sur une architecture distribuée conteneurisée gérée via docker-compose.yml. Il comprend 12 services distincts interagissant en réseau.

Conteneur	Image Base	Rôle Technique Explicite
postgres-mirror	postgres:16	Réplique relationnelle. Contient les tables courses, users, etc., servant de source de vérité pour les imports Sqoop.
namenode	hadoop-namenode:2.7.4	Maître HDFS. Gère les métadonnées du système de fichiers distribué et les allocations de blocs de données.
datanode	hadoop-datanode:2.7.4	Esclave HDFS. Stocke physiquement les blocs de données distribués sur ses disques locaux.
resourcemanager	hadoop-resourcemanager	Maître YARN. Alloue les ressources CPU/RAM pour l'exécution des jobs MapReduce distribués.
nodemanager	hadoop-nodemanager	Esclave YARN. Exécute les tâches Map/Reduce sur les serveurs individuels.
hive-metastore-postgresql	postgresql	Base de données relationnelle interne stockant les métadonnées (schémas, tables) pour Apache Hive.
hive-metastore	hive:2.3.2	Service abstrait exposant le catalogue de schémas aux clients Hive et Spark.
hive-server	hive:2.3.2	Moteur d'exécution des requêtes HiveQL (via JDBC/Beeline) transformant le SQL en jobs MapReduce.
sqoop-client	custom skillbridge-sqoop	Outil d'ingestion batch. Déplace les données entre le Postgres-mirror et HDFS.
flume-agent	custom skillbridge-flume	Agent d'ingestion streaming. Écoute le fichier events.log du backend web et transfère les logs JSON vers HDFS en temps réel.
hbase	harisekhon/hbase	Base de données NoSQL orientée colonnes, offrant un accès O(1) aux statistiques de popularité pour les recommandations rapides de l'interface web.

2. Dictionnaire Complet des Fichiers (Dossier apps/bigdata)

Le pipeline Big Data est orchestré par de multiples scripts et configurations. Voici l'explication détaillée de chacun d'eux :

A. Scripts d'Orchestration (Dossier scripts/)

00_check_prereqs.ps1 : Script PowerShell vérifiant la présence de Docker, Python, Java, et les dépendances nécessaires avant de lancer le pipeline.

03_create_hdfs_dirs.sh : Script bash qui s'exécute dans le namenode pour préparer les répertoires racines HDFS (ex: /data/skillbridge/raw, /data/skillbridge/processed).

04_sqoop_import_mvp.sh : Lance les commandes sqoop import pour rapatrier les tables relationnelles depuis postgres-mirror vers HDFS.

06_run_hive_queries.sh : Exécute via Beeline les scripts SQL pour créer les tables externes Hive et exécuter les requêtes de démonstration.

07_run_mapreduce.ps1 / .sh : Compile et exécute le job Java MapReduce (TopSearchKeywordsJob) sur le cluster Hadoop pour analyser les recherches textuelles.

08_match_project_skills.py : Script Python qui implémente une logique d'association NLP pour lier des compétences aux descriptions de projets.

09_load_course_stats_hbase.py : Extrait les statistiques de PostgreSQL et HDFS, compile le fichier bigdata-summary.json et génère le script de chargement pour HBase (load_course_stats.hbase).

10_run_mvp_pipeline.ps1 : Le script principal qui orchestre toute la séquence (Sqoop -> Hive -> MapReduce -> Python -> HBase).

12_merge_and_enrich_catalog.py & 13_push_catalog_to_supabase.py : Scripts avancés Python de préparation des données pour le catalogue web.

14_seed_postgres_mirror_from_catalog.py : Remplit la base miroir Postgres avec un jeu de données initial généré ou mocké.

B. Code Java MapReduce

TopSearchKeywordsJob.java : Implémente la classe Mapper pour extraire les mots (nettoyés des stop-words) depuis les logs JSON Flume de type COURSE_SEARCH, et la classe Reducer pour agréger et compter les occurrences de chaque mot.

C. Configurations

flume/skillbridge-events.conf : Définit la source (Exec source sur tail -F events.log), le canal (en mémoire), et le puits (HDFS Sink avec rotation des fichiers) pour Apache Flume.

hive/01_create_hive_tables.sql : Création des tables EXTERNAL pointant vers les répertoires Sqoop et Flume dans HDFS.

3. Explication Approfondie des Outils du Pipeline

3.1 Apache Sqoop (Import Relationnel)

Rôle : Extraire en masse des données structurées depuis le `postgres-mirror` vers HDFS.

Fonctionnement détaillé : Sqoop connecte Hadoop à Postgres via JDBC. Pour chaque table (ex: courses, users), il génère automatiquement du code Java (des classes ORM), divise la table selon sa clé primaire, et lance des tâches Map() parallèles pour copier les lignes directement dans HDFS sous forme de fichiers texte (valeurs séparées par des tabulations).

Exemple de commande générée par 04_sqoop_import_mvp.sh :

```
sqoop import --connect jdbc:postgresql://postgres-mirror:5432/skillbridge --username skillbridge --password skillbridge --table courses --target-dir /data/skillbridge/raw/sqoop/courses -m 1
```

3.2 Apache Flume (Ingestion Streaming Temps Réel)

Rôle : Capturer les clics et recherches générés par le serveur Spring Boot et les écrire dans HDFS.

Fonctionnement détaillé : Le backend Spring Boot génère un fichier log local events.log contenant des JSON Lines grâce à BigDataEventService.java (protégé par un ReentrantLock pour éviter la corruption). L'agent Flume possède une source de type exec qui écoute les ajouts de ce fichier (comme la commande Unix tail -F). Les données traversent un *Memory Channel* puis sont poussées par un *HDFS Sink* qui crée un nouveau fichier dans Hadoop toutes les minutes ou selon la taille.

Extrait de skillbridge-events.conf :

```
agent.sources.eventSource.type = exec agent.sources.eventSource.command = tail -F /opt/skillbridge/data/events/events.log agent.sinks.hdfsSink.type = hdfs agent.sinks.hdfsSink.hdfs.path = hdfs://namenode:9000/data/skillbridge/raw/flume/events agent.sinks.hdfsSink.hdfs.fileType = DataStream
```

3.3 Hadoop HDFS (Système de Fichiers Distribués)

Rôle : Servir de Data Lake central, unifiant les données structurées de Sqoop et les données semi-structurées de Flume.

Fonctionnement détaillé : Divise les gros fichiers en blocs de 128 MB et les distribue sur les datanodes avec une réplication de 2 (pour la tolérance aux pannes). Le namenode conserve l'arborescence (répertoires /data/skillbridge/*) en mémoire RAM pour un accès ultra-rapide aux métadonnées.

3.4 Apache Hive (Data Warehouse & BI)

Rôle : Fournir une interface SQL standard sur les fichiers textes HDFS sans avoir à écrire de code Java MapReduce.

Fonctionnement détaillé : Utilise le concept de *Schema-on-Read*. Les tables sont définies comme EXTERNAL, c'est-à-dire que Hive ne copie pas les données, il ne fait qu'y associer une structure logique. Pour analyser les logs Flume qui sont au format JSON, Hive utilise ses UDFs (*User Defined Functions*) natives comme `get_json_object()`.

Requête d'analyse des compétences tendances (02_demo_queries.sql) :

```
SELECT s.name, COUNT(*) AS total_courses FROM hive_course_skills cs JOIN hive_skills s ON s.id = cs.skill_id GROUP BY s.name ORDER BY total_courses DESC LIMIT 10;
```

3.5 Hadoop MapReduce (Calcul Distribué Avancé)

Rôle : Analyser textuellement le champ JSON query des événements pour identifier les mots-clés les plus populaires.

Fonctionnement détaillé : Le script Java définit une fonction *Map* qui s'exécute sur les nœuds contenant les données HDFS, découpe les phrases de recherche en mots, filtre les « mots vides » (stop-words), et émet des paires clé/valeur (mot, 1). La phase de *Shuffle/Sort* regroupe ces valeurs par mot, et la fonction *Reduce* additionne les 1 pour obtenir un compte final distribué (mot, N).

3.6 Apache HBase (Cache Analytique NoSQL)

Rôle : Fournir des lectures à très faible latence (millisecondes) des résultats analytiques aux applications web.

Fonctionnement détaillé : Contrairement à Hive qui scanne tout le fichier pour répondre, HBase indexe les données par une clé (ici l'ID du cours). Le script Python `09_load_course_stats_hbase.py` fusionne les statistiques de Hive et l'activité événementielle en un script de commandes HBase Shell. Le serveur backend Spring Boot lit ces données via l'API pour ajouter instantanément un « bonus de popularité » (+10 points) aux recommandations de l'étudiant.

4. Guide des Commandes Terminal (Exécution & Démonstration)

Cette section liste les commandes que vous pouvez taper ou copier/coller dans votre terminal (à la racine du dossier apps/bigdata) pour démontrer le fonctionnement de chaque outil en temps réel. Assurez-vous que le cluster Docker est démarré.

A. Gestion du Cluster Docker

Démarrer tous les conteneurs en arrière-plan :

```
docker compose up -d
```

Vérifier les logs du namenode Hadoop :

```
docker compose logs -f namenode
```

B. Exploration de HDFS

Vérifier la santé du cluster Hadoop (SafeMode, Noeuds Actifs) :

```
docker compose exec namenode hdfs dfsadmin -report
```

Lister tous les fichiers bruts importés par Sqoop :

```
docker compose exec namenode hdfs dfs -ls /data/skillbridge/raw/sqoop
```

Lire le contenu des événements ingérés par Flume (affiche les JSON générés par l'interface web) :

```
docker compose exec namenode hdfs dfs -cat /data/skillbridge/raw/flume/events/* | head -n 20
```

C. Exécution des requêtes SQL Hive

Ouvrir l'invite interactive Beeline connectée au serveur Hive :

```
docker compose exec hive-server beeline -u jdbc:hive2://localhost:10000
```

(Une fois dans Beeline, vous pouvez taper :)

```
USE skillbridge_bigdata; SHOW TABLES; SELECT COUNT(*) FROM hive_events;
```

D. Interactions Sqoop

Exécuter une évaluation rapide (tester la connexion et lister les bases PostgreSQL) :

```
docker compose exec sqoop-client sqoop eval --connect  
jdbc:postgresql://postgres-mirror:5432/skillbridge --username skillbridge --password  
skillbridge --query "SELECT count(*) FROM courses"
```

E. Interactions HBase

Ouvrir le shell interactif HBase :

```
docker compose exec hbase hbase shell
```

(Une fois dans HBase, vous pouvez scanner la table des statistiques :)

```
scan 'course_stats', {LIMIT => 5}
```

F. Automatisation Globale (Orchestrateur)

Si vous êtes sur Windows PowerShell, vous pouvez lancer le pipeline Big Data complet d'une seule traite (qui rafraîchira Sqoop, Hive, MapReduce et HBase) :

```
.\scripts\10_run_mvp_pipeline.ps1
```