

RAPPORT TECHNIQUE DETAILLE

SkillBridge Big Data Deep Dive: conteneurs, fichiers, code, pipeline et commandes de demonstration

Ce PDF explique en profondeur tout le module `apps/bigdata` : role de chaque conteneur, role de chaque fichier, fonctionnement de Sqoop, Flume, HDFS, Hive, HBase et MapReduce, impact sur les use cases web, et commandes terminal pour prouver chaque partie.

17072

cours unifies

13647

skills

104006


liens course-skill

11conteneurs
documentes

Generation basee sur les fichiers du repository, les rapports `output/*.json` et les commandes Docker/HDFS/Hive disponibles localement.

1. Architecture generale Big Data

Figure 1 - Flux global donnees et analytics



Le pipeline est separe en deux mondes: Supabase comme base officielle de l'application, et PostgreSQL mirror + Hadoop comme laboratoire Big Data. Cette separation evite de mettre Hadoop dans le chemin critique des requetes web.

Couche	Responsabilite	Impact	
Sqaop	Collecte batch	Lit les tables PostgreSQL mirror via JDBC et écrit des fichiers texte tabulés dans HDFS.	Prouve l'import relationnel massif vers Big Data.
Flume	Collecte streaming	Suit events.log et envoie les lignes JSON vers HDFS avec source exec, channel memory, sink HDFS.	Relie les actions web au data lake.
HDFS	Stockage distribué	Stocke les zones raw/sqaop, raw/flume, processed/mapreduce.	Base commune pour Hive et MapReduce.
Hive	SQL analytique	Déclare des tables externes sur les dossiers HDFS et lance les requêtes demo.	Permet d'expliquer les données avec SQL.
MapReduce	Traitement distribué Java	Mapper extrait les tokens des événements COURSE_SEARCH/PROJECT_RECOMMENDATION, Reducer somme les compteurs.	Produit les top mots-clés recherchés.
HBase	Serving key/value	Table course_stats avec familles meta et activity.	Expose des statistiques rapides par course_id.
Python	Préparation et traitement métier	Nettoyage catalogue, seed mirror, matching projet-skill, génération scripts HBase.	Fait le lien business entre web app et pipeline.

2. Etat Docker observe pendant la generation

Cette sortie montre les conteneurs visibles via Docker au moment de produire le rapport.

NAMES	IMAGE	STATUS	PORTS
sad_mahavira	ghcr.io/github/github-mcp-server	Up 6 hours	8082/tcp
skillbridge-flume-agent	skillbridge-flume:1.9.0-hadoop2.7.4	Up 6 hours	
bigdata-datanode-2	bde2020/hadoop-datanode:2.0.0-hadoop2.7.4-java8	Up 6 hours (healthy)	50075/tcp
bigdata-datanode-1	bde2020/hadoop-datanode:2.0.0-hadoop2.7.4-java8	Up 6 hours (healthy)	50075/tcp
skillbridge-sqoop-client	skillbridge-sqoop:1.4.7-hadoop2.7.4	Up 6 hours	
skillbridge-hbase	harisekhon/hbase:latest	Up 6 hours	
0.0.0.0:16010->16010/tcp, [::]:16010->16010/tcp			
skillbridge-hive-server	bde2020/hive:2.3.2-postgresql-metastore	Up 6 hours	
0.0.0.0:10000->10000/tcp, [::]:10000->10000/tcp			
skillbridge-hive-metastore	bde2020/hive:2.3.2-postgresql-metastore	Up 6 hours	
0.0.0.0:9083->9083/tcp, [::]:9083->9083/tcp			
skillbridge-hive-metastore-postgresql	bde2020/hive-metastore-postgresql:2.3.0	Up 6 hours	5432/tcp
skillbridge-nodemanager	bde2020/hadoop-nodemanager:2.0.0-hadoop2.7.4-java8	Up 6 hours (healthy)	
0.0.0.0:8042->8042/tcp, [::]:8042->8042/tcp			
skillbridge-resourcemanager	bde2020/hadoop-resourcemanager:2.0.0-hadoop2.7.4-java8	Up 6 hours (healthy)	
0.0.0.0:8088->8088/tcp, [::]:8088->8088/tcp			
skillbridge-namenode	bde2020/hadoop-namenode:2.0.0-hadoop2.7.4-java8	Up 6 hours (healthy)	
0.0.0.0:9000->9000/tcp, [::]:9000->9000/tcp, 0.0.0.0:9870->50070/tcp, [::]:9870->50070/tcp			
skillbridge-postgres-mirror	postgres:16	Up 6 hours	
0.0.0.0:5433->5432/tcp, [::]:5433->5432/tcp			

3. Detail exhaustif des conteneurs

Conteneur	Image	Fonction	Impact metier	Port	Commande demo
postgres-mirror	postgres:16	Source relationnelle locale pour le pipeline	Reçoit le catalogue CSV nettoyé. Sqoop lit cette base au lieu de toucher Supabase.	5433:5432	docker exec skillbridge-postgres-mirror psql -U skillbridge -d skillbridge -c "select count(*) from courses;"
namenode	bde2020/hadoop-namenode	Maître HDFS	Gère les métadonnées HDFS: noms de fichiers, chemins, blocs, réplication.	9870, 9000	docker exec skillbridge-namenode hdfs dfsadmin -report
datanode	bde2020/hadoop-datanode	Stockage HDFS	Stocke physiquement les blocs HDFS. Le projet démarre deux DataNodes pour montrer la distribution.	50075 interne	docker ps --filter name=bigdata-datanode
resourcemanager	bde2020/hadoop-resourcemanager	Planificateur YARN	Coordonne l'exécution des traitements MapReduce/YARN.	8088	docker logs skillbridge-resourcemanager --tail 40
nodemanager	bde2020/hadoop-nodemanager	Worker YARN	Exécute les tâches que YARN lui assigne.	8042	docker logs skillbridge-nodemanager --tail 40
sqoop-client	skillbridge-sqoop	Collecte batch PostgreSQL -> HDFS	Importe providers, categories, skills, courses, course_skills, project_ideas, saved_courses, course_progress.	-	docker exec skillbridge-sqoop-client bash /opt/skillbridge/scripts/04_sqoop_import_mvp.sh
flume-agent	skillbridge-flume	Collecte streaming events.log -> HDFS	Suit le fichier events.log et pousse chaque ligne JSON vers HDFS.	-	docker logs skillbridge-flume-agent --tail 80
hive-metastore-postgresql	bde2020/hive-metastore-postgresql	Base interne du metastore Hive	Stocke les métadonnées Hive: bases, tables, colonnes, emplacements HDFS.	5432 interne	docker logs skillbridge-hive-metastore-postgresql --tail 40
hive-metastore	bde2020/hive	Service metastore Hive	Expose les définitions de tables à Hive Server.	9083	docker logs skillbridge-hive-metastore --tail 40
hive-server	bde2020/hive	Serveur SQL Hive	Permet d'exécuter Beeline et les requêtes SQL sur les fichiers HDFS.	10000	docker exec skillbridge-hive-server beeline -u jdbc:hive2://localhost:10000 -e "show databases;"
hbase	harisekhon/hbase	Serving key/value course_stats	Stocke les statistiques finales par course_id: clicks, saves, avg_progress, title.	16010	docker exec -i skillbridge-hbase /hbase/bin/hbase shell -n

Explication par conteneur

postgres-mirror

Role: Source relationnelle locale pour le pipeline. Reçoit le catalogue CSV nettoyé. Sqoop lit cette base au lieu de toucher Supabase.

Commande de preuve: `docker exec skillbridge-postgres-mirror psql -U skillbridge -d skillbridge -c "select count(*) from courses;"`

namenode

Role: Maître HDFS. Gère les métadonnées HDFS: noms de fichiers, chemins, blocs, réplication.

Commande de preuve: `docker exec skillbridge-namenode hdfs dfsadmin -report`

datanode

Role: Stockage HDFS. Stocke physiquement les blocs HDFS. Le projet démarre deux DataNodes pour montrer la distribution.

Commande de preuve: `docker ps --filter name=bigdata-datanode`

resourcemanager

Role: Planificateur YARN. Coordonne l'exécution des traitements MapReduce/YARN.

Commande de preuve: `docker logs skillbridge-resourcemanager --tail 40`

nodemanager

Role: Worker YARN. Exécute les tâches que YARN lui assigne.

Commande de preuve: `docker logs skillbridge-nodemanager --tail 40`

sqoop-client

Role: Collecte batch PostgreSQL -> HDFS. Importe providers, categories, skills, courses, course_skills, project_ideas, saved_courses, course_progress.

Commande de preuve: `docker exec skillbridge-sqoop-client bash /opt/skillbridge/scripts/04_sqoop_import_mvp.sh`

flume-agent

Role: Collecte streaming events.log -> HDFS. Suit le fichier events.log et pousse chaque ligne JSON vers HDFS.

Commande de preuve: `docker logs skillbridge-flume-agent --tail 80`

hive-metastore-postgresql

Role: Base interne du metastore Hive. Stocke les métadonnées Hive: bases, tables, colonnes, emplacements HDFS.

Commande de preuve: `docker logs skillbridge-hive-metastore-postgresql --tail 40`

hive-metastore

Role: Service metastore Hive. Expose les définitions de tables à Hive Server.

Commande de preuve: `docker logs skillbridge-hive-metastore --tail 40`

hive-server

Role: Serveur SQL Hive. Permet d'exécuter Beeline et les requêtes SQL sur les fichiers HDFS.

Commande de preuve: `docker exec skillbridge-hive-server beeline -u jdbc:hive2://localhost:10000 -e "show databases;"`

hbase

Role: Serving key/value course_stats. Stocke les statistiques finales par course_id: clicks, saves, avg_progress, title.

Commande de preuve: `docker exec -i skillbridge-hbase /hbase/bin/hbase shell -n`

4. Inventaire de chaque fichier Big Data

Cette table documente le role de chaque fichier source ou artefact important dans `apps/bigdata`.

Fichier	Rôle détaillé
README.md	Documentation principale du module Big Data: architecture, rôles, commandes, erreurs fréquentes.
docker-compose.yml	Déclare tous les conteneurs: PostgreSQL mirror, Hadoop, Sqoop, Flume, Hive, HBase.
.env.example	Variables locales: chemins ZIP, HDFS_BASE, HIVE_DATABASE, connexion mirror.
requirements.txt	Dépendances Python, notamment psycopg2-binary.
data/events/events.log.example	Événements web de démonstration au format JSON Lines.
data/events/events.log	Fichier runtime écrit par Spring Boot et suivi par Flume.
data/raw/README.md	Zone explicative pour les données brutes locales.
flume/skillbridge-events.conf	Configuration source/channel/sink Flume.
conf/hive/hive-site.xml	Connexion Hive au metastore PostgreSQL et options Hive.
docker/sqoop/Dockerfile	Image locale Sqoop compatible Hadoop 2.7.4 + PostgreSQL JDBC.
docker/flume/Dockerfile	Image locale Flume avec librairies Hadoop nécessaires.
mapreduce/pom.xml	Build Maven du job Java MapReduce.
mapreduce/src/main/java/com/skillbridge/bigdata/TopSearchKeywordsJob.java	Mapper/Reducer qui compte les mots-clés dans les événements.
sql/postgres/01_create_seed_schema.sql	Schema local minimal pour le PostgreSQL mirror.
sql/postgres/02_seed_project_ideas.sql	Jeu de projets de démonstration pour le mirror.
sql/hive/01_create_hive_tables.sql	Tables externes Hive pointant vers les dossiers HDFS.
sql/hive/02_demo_queries.sql	Requêtes analytiques: counts, top providers, top categories, top skills, events.
sql/hbase/01_create_course_stats.hbase	Script HBase de création de table course_stats.
scripts/00_check_prereqs.ps1	Vérifie Docker, Python, Maven wrapper, datasets.
scripts/03_create_hdfs_dirs.sh	Crée /data/skillbridge/raw, processed, export, hive.
scripts/04_sqoop_import_mvp.sh	Importe les tables du mirror vers HDFS avec Sqoop.
scripts/06_run_hive_queries.sh	Lance les scripts Hive de création et requêtes demo.
scripts/07_run_mapreduce.ps1	Compile le job Java puis l'exécute dans Hadoop.
scripts/07_run_mapreduce.sh	Commande Hadoop jar dans le namenode.
scripts/08_match_project_skills.py	Détecte les skills dans les projets du mirror.
scripts/09_load_course_stats_hbase.py	Génère load_course_stats.hbase et bigdata-summary.json.
scripts/10_run_mvp_pipeline.ps1	Orchestre le pipeline Big Data MVP complet.
scripts/12_merge_and_enrich_catalog.py	Lit les ZIP, nettoie, déduplique, catégorise, écrit les CSV catalogue.
scripts/13_push_catalog_to_supabase.py	Dry-run ou upsert safe vers Supabase catalogue.
scripts/14_seed_postgres_mirror_from_catalog.py	Remplit le PostgreSQL mirror depuis les CSV catalogue.
scripts/15_run_project_recommendation.py	CLI terminal de recommandation à partir d'un texte projet.

Fichier	Rôle détaillé
scripts/16_run_catalog_build.ps1	Wrapper PowerShell du build catalogue.
scripts/17_push_catalog_to_supabase.ps1	Wrapper PowerShell du push Supabase.
scripts/18_run_full_terminal_lab.ps1	Pipeline complet: catalog -> Supabase -> mirror -> Sqoop -> Flume -> Hive -> MapReduce -> Python -> HBase -> CLI.
scripts/19_clean_bigdata_runtime.ps1	Nettoyage sûr des fichiers générés.
scripts/20_verify_app_bigdata_link.ps1	Vérifie que Spring Boot voit le catalogue Big Data via /api/courses.
scripts/21_sync_supabase_sequences.py	Resynchronise les séquences PostgreSQL Supabase après imports explicites.
scripts/flume-follow-events.sh	Follower compatible Windows/volume Docker pour envoyer les nouvelles lignes à Flume.
output/catalog/*.csv	Livrables catalogue générés.
output/bigdata-summary.json	Résumé final lu par le backend/admin dashboard.
output/recommendation_result.json	Dernier résultat de recommandation web ou CLI.
output/load_course_stats.hbase	Script HBase généré avec les put course_stats.

5. Installation et preparation des donnees

Les donnees viennent de ZIP locaux. Le script `12_merge_and_enrich_catalog.py` nettoie les titres, descriptions, niveaux, providers, URLs, skills, categories, scores de popularite et supprime les doublons.

Source	Raw	Utilise	Ignore
final_cleaned_dataset.csv	2377	2377	0
all_courses.csv	1041	1041	0
processed_coursera_data.json	13174	13173	1
edx_courses.json	1000	1000	0

Commandes

```
cd apps\\bigdata\\npython -m pip install -r requirements.txt\npython .\\scripts\\12_merge_and_enrich_catalog.py\nGet-Content .\\output\\catalog\\catalog_build_report.json
```

Impact

Sans cette etape, le web n'a pas un catalogue propre et le pipeline Hadoop n'a pas de tables coherentes a importer.

6. Sqoop: collecte batch PostgreSQL vers HDFS

`04_sqoop_import_mvp.sh` importe huit tables du mirror vers HDFS. Chaque table devient un dossier sous `/data/skillbridge/raw/sqoop/<table>` avec `part-m-00000` et `_SUCCESS`.

Tables importees

- providers
- categories
- skills
- courses
- course_skills
- project_ideas
- saved_courses
- course_progress

Preuve mirror PostgreSQL

```
table_name | count
-----+-----
courses   | 17072
skills     | 13647
course_skills | 104006
project_ideas | 10
saved_courses | 40
course_progress | 50
(6 rows)
```

Commande de demonstration

```
docker exec skillbridge-sqoop-client bash /opt/skillbridge/scripts/04_sqoop_import_mvp.sh\ndocker exec skillbridge-namenode hdfs dfs -ls /data/skillbridge/raw/sqoop/courses\ndocker exec skillbridge-namenode hdfs dfs -cat /data/skillbridge/raw/sqoop/courses/part-m-00000 | head
```

7. HDFS: stockage distribue

HDFS est le stockage central. Sqoop y depose le batch, Flume y depose le streaming, MapReduce y lit et y ecrit ses resultats.

Arborescence observee

```
drwxr-xr-x - root supergroup          0 2026-04-20 09:48 /data/skillbridge/export\ndrwxr-xr-x - root supergroup          0
2026-04-20 09:48 /data/skillbridge/export/hbase\ndrwxr-xr-x - root supergroup          0 2026-04-20 09:48
/data/skillbridge/hive\ndrwxr-xr-x - root supergroup          0 2026-04-20 09:48 /data/skillbridge/processed\ndrwxr-xr-x -
root supergroup          0 2026-05-12 14:13 /data/skillbridge/processed/mapreduce\ndrwxr-xr-x - root supergroup          0 2026-
05-12 14:13 /data/skillbridge/processed/mapreduce/top_search_keywords\n-rw-r--r-- 2 root supergroup          0 2026-05-12 14:13
/data/skillbridge/processed/mapreduce/top_search_keywords/_SUCCESS\n-rw-r--r-- 2 root supergroup          166 2026-05-12 14:13
/data/skillbridge/processed/mapreduce/top_search_keywords/part-r-00000\ndrwxr-xr-x - root supergroup          0 2026-04-20 09:48
/data/skillbridge/processed/python\ndrwxr-xr-x - root supergroup          0 2026-04-20 09:48 /data/skillbridge/raw\ndrwxr-xr-x
- root supergroup          0 2026-04-20 09:48 /data/skillbridge/raw/flume\ndrwxr-xr-x - root supergroup          0 2026-05-20
17:17 /data/skillbridge/raw/flume/events\n-rw-r--r-- 2 root supergroup          870 2026-04-20 10:06
/data/skillbridge/raw/flume/events/events.1776679507079\n-rw-r--r-- 2 root supergroup          1364 2026-04-20 10:08
/data/skillbridge/raw/flume/events/events.1776679669807\n-rw-r--r-- 2 root supergroup          980 2026-04-20 15:00
/data/skillbridge/raw/flume/events/events.1776697159650\n-rw-r--r-- 2 root supergroup          980 2026-04-21 14:56
/data/skillbridge/raw/flume/events/events.1776783351033\n-rw-r--r-- 2 root supergroup          980 2026-04-22 07:57
/data/skillbridge/raw/flume/events/events.1776844533695\n-rw-r--r-- 2 root supergroup          156 2026-05-12 13:58
/data/skillbridge/raw/flume/events/events.1778594317723\n-rw-r--r-- 3 root supergroup          246 2026-05-20 17:15
/data/skillbridge/raw/flume/events/events.1779297307896\n-rw-r--r-- 3 root supergroup          415 2026-05-20 17:15
/data/skillbridge/raw/flume/events/events.1779297332916\n-rw-r--r-- 3 root supergroup          120 2026-05-20 17:17
/data/skillbridge/raw/flume/events/events.1779297456331\ndrwxr-xr-x - root supergroup          0 2026-04-21 14:55
/data/skillbridge/raw/sqoop\ndrwxr-xr-x - root supergroup          0 2026-04-21 14:51 /data/skillbridge/raw/sqoop/categories\n-
rw-r--r-- 2 root supergroup          0 2026-04-21 14:51 /data/skillbridge/raw/sqoop/categories/_SUCCESS\n-rw-r--r-- 2 root
supergroup          2023 2026-04-21 14:51 /data/skillbridge/raw/sqoop/categories/part-m-00000\ndrwxr-xr-x - root supergroup
0 2026-04-21 14:55 /data/skillbridge/raw/sqoop/course_progress\n-rw-r--r-- 2 root supergroup          0 2026-04-21 14:55
/data/skillbridge/raw/sqoop/course_progress/_SUCCESS\n-rw-r--r-- 2 root supergroup          4206 2026-04-21 14:55
/data/skillbridge/raw/sqoop/course_progress/part-m-00000\ndrwxr-xr-x - root supergroup          0 2026-04-21 14:53
/data/skillbridge/raw/sqoop/course_skills\n-rw-r--r-- 2 root supergroup          0 2026-04-21 14:53
/data/skillbridge/raw/sqoop/course_skills/_SUCCESS\n-rw-r--r-- 2 root supergroup          1099200 2026-04-21 14:53
/data/skillbridge/raw/sqoop/course_skills/part-m-00000\ndrwxr-xr-x - root supergroup          0 2026-04-21 14:53
/data/skillbridge/raw/sqoop/courses\n-rw-r--r-- 2 root supergroup          0 2026-04-21 14:53
/data/skillbridge/raw/sqoop/courses/_SUCCESS\n-rw-r--r-- 2 root supergroup          38823808 2026-04-21 14:53
/data/skillbridge/raw/sqoop/courses/part-m-00000\ndrwxr-xr-x - root supergroup          0 2026-04-21 14:54
/data/skillbridge/raw/sqoop/project_ideas\n-rw-r--r-- 2 root supergroup          0 2026-04-21 14:54
/data/skillbridge/raw/sqoop/project_ideas/_SUCCESS\n-rw-r--r-- 2 root supergroup          1888 2026-04-21 14:54
/data/skillbridge/raw/sqoop/project_ideas/part-m-00000\ndrwxr-xr-x - root supergroup          0 2026-04-21 14:51
/data/skillbridge/raw/sqoop/providers\n-rw-r--r-- 2 root supergroup          0 2026-04-21 14:51
/data/skillbridge/raw/sqoop/providers/_SUCCESS\n-rw-r--r-- 2 root supergroup          72193 2026-04-21 14:51
/data/skillbridge/raw/sqoop/providers/part-m-00000\ndrwxr-xr-x - root supergroup          0 2026-04-20 09:48
/data/skillbridge/raw/sqoop/roles\ndrwxr-xr-x - root supergroup          0 2026-04-21 14:54
/data/skillbridge/raw/sqoop/saved_courses\n-rw-r--r-- 2 root supergroup          0 2026-04-21 14:54
/data/skillbridge/raw/sqoop/saved_courses/_SUCCESS\n-rw-r--r-- 2 root supergroup          1471 2026-04-21 14:54
/data/skillbridge/raw/sqoop/saved_courses/part-m-00000\ndrwxr-xr-x - root supergroup          0 2026-04-21 14:52
/data/skillbridge/raw/sqoop/skills\n-rw-r--r-- 2 root supergroup          0 2026-04-21 14:52
/data/skillbridge/raw/sqoop/skills/_SUCCESS\n-rw-r--r-- 2 root supergroup          2136362 2026-04-21 14:52
/data/skillbridge/raw/sqoop/skills/part-m-00000\ndrwxr-xr-x - root supergroup          0 2026-04-20 09:48
/data/skillbridge/raw/sqoop/users
```

Commandes utiles

```
docker exec skillbridge-namenode hdfs dfsadmin -report\ndocker exec skillbridge-namenode hdfs dfs -ls -R /data/skillbridge\ndocker
exec skillbridge-namenode hdfs dfs -du -h /data/skillbridge/raw/sqoop\ndocker exec skillbridge-namenode hdfs dfs -cat
/data/skillbridge/processed/mapreduce/top_search_keywords/part-r-00000
```

8. Flume: streaming des evenements web

Spring Boot ecrit des lignes JSON dans `data/events/events.log`. Flume utilise une source `exec` qui lance `flume-follow-events.sh`, un channel memoire, et un sink HDFS.

Evenements supportes

- `COURSE_SEARCH` : recherche catalogue.
- `COURSE_CLICK` : clic vers un cours externe.
- `COURSE_SAVE` : sauvegarde cours.
- `PROJECT_CREATED` : creation idee.
- `PROJECT_RECOMMENDATION` : generation recommandations.

Derniers evenements locaux

```
{
  "eventType": "PROJECT_RECOMMENDATION",
  "source": "web-app",
  "timestamp": "2026-05-11T22:54:43.178043Z",
  "userId": 1,
  "projectId": 23,
  "projectTitle": "Learn the backend skills needed for...",
  "projectDescription": "Learn the backend skills needed for a booking app",
  "requestedLimit": 10,
  "detectedSkills": ["G Skills"],
  "matchedCategories": ["Backend Development"],
  "topRecommendedCourseIds": [4905, 11851, 1154, 1201, 4849, 12680, 12687, 4906, 4907, 4929],
  "scores": [33, 29, 27, 27, 27, 27, 27, 27, 27, 27]
}
{
  "eventType": "PROJECT_CREATED",
  "source": "web-app",
  "timestamp": "2026-05-12T10:43:11.515834Z",
  "userId": 1,
  "projectId": 24,
  "projectTitle": "i want to creat a complete...",
  "projectDescription": "i want to creat a complete fulstack project with postgresql"
}
{
  "eventType": "PROJECT_RECOMMENDATION",
  "source": "web-app",
  "timestamp": "2026-05-12T10:43:19.919067700Z",
  "userId": 1,
  "projectId": 24,
  "projectTitle": "i want to creat a complete...",
  "projectDescription": "i want to creat a complete fulstack project with postgresql",
  "requestedLimit": 5,
  "detectedSkills": ["PostgreSQL"],
  "matchedCategories": ["Databases"],
  "topRecommendedCourseIds": [5134, 5266, 5267, 6575, 15532],
  "scores": [61, 55, 55, 54, 54]
}
{
  "eventType": "COURSE_SAVE",
  "source": "web-app",
  "timestamp": "2026-05-12T10:43:46.525589600Z",
  "userId": 1,
  "courseId": 5134
}
{
  "eventType": "PIPELINE_REPORT_TEST",
  "source": "codex-report",
  "timestamp": "2026-05-12T11:18:59.4738864Z",
  "message": "verification flume events.log to hdfs"
}
{
  "message": "verify append with FileShare while flume tails",
  "timestamp": "2026-05-12T13:56:00.8636821Z",
  "source": "codex-fix",
  "eventType": "PIPELINE_FIX_TEST_DOTNET"
}
{
  "message": "verify flume polling follower to hdfs",
  "timestamp": "2026-05-12T13:58:35.6069489Z",
  "source": "codex-fix",
  "eventType": "PIPELINE_FIX_TEST_POLLING"
}
{
  "eventType": "PROJECT_CREATED",
  "source": "web-app",
  "timestamp": "2026-05-20T17:15:03.805106400Z",
  "userId": 8,
  "projectId": 39,
  "projectTitle": "Create a small AI study assistant...",
  "projectDescription": "Create a small AI study assistant for students"
}
{
  "eventType": "PROJECT_RECOMMENDATION",
  "source": "web-app",
  "timestamp": "2026-05-20T17:15:30.383022900Z",
  "userId": 8,
  "projectId": 39,
  "projectTitle": "Create a small AI study assistant...",
  "projectDescription": "Create a small AI study assistant for students",
  "requestedLimit": 5,
  "detectedSkills": [],
  "matchedCategories": ["Machine Learning"],
  "topRecommendedCourseIds": [16360, 1922, 9073, 12326, 16343],
  "scores": [38, 33, 32, 32, 32]
}
{
  "eventType": "COURSE_SAVE",
  "source": "web-app",
  "timestamp": "2026-05-20T17:17:34.197671800Z",
  "userId": 8,
  "courseId": 16360
}
```

Commandes de demonstration

```
Add-Content .\data\events\events.log '{"eventType":"COURSE_SEARCH","source":"demo","timestamp":"2026-05-20T00:00:00Z","query":"spring hive hadoop"}'
docker logs skillbridge-flume-agent --tail 80
docker exec skillbridge-namenode hdfs dfs -ls -R /data/skillbridge/raw/flume/events
docker exec skillbridge-namenode hdfs dfs -cat /data/skillbridge/raw/flume/events/<events-file>
```

9. Hive: SQL analytique sur HDFS

Hive ne copie pas les données: il crée des tables externes sur les dossiers HDFS. Les fichiers Sqoop tabulés deviennent des tables SQL. Les événements Flume sont lus comme lignes brutes JSON et interrogés avec `get_json_object`.

Counts Hive observes

```
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/opt/hive/lib/log4j-slf4j-impl-2.6.2.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/opt/hadoop-2.7.4/share/hadoop/common/lib/slf4j-log4j12-1.7.10.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
+-----+
| hive_courses |
+-----+
| 17072        |
+-----+
+-----+
| hive_events  |
+-----+
| 62           |
+-----+
```

Commandes demo

```
docker exec skillbridge-hive-server bash /opt/skillbridge/scripts/06_run_hive_queries.sh
docker exec skillbridge-hive-server beeline -u jdbc:hive2://localhost:10000 --silent=true --showHeader=true --outputformat=table -
e "use skillbridge_bigdata; select level, count(*) from hive_courses group by level;"
docker exec skillbridge-hive-server beeline -u jdbc:hive2://localhost:10000 --silent=true --showHeader=true --outputformat=table -
e "use skillbridge_bigdata; select get_json_object(raw_line, '$.eventType') event_type, count(*) from hive_events group by
get_json_object(raw_line, '$.eventType');"
```

10. MapReduce: TopSearchKeywordsJob

Le job Java lit les evenements HDFS. Le Mapper ignore les evenements qui ne sont pas `COURSE_SEARCH` ou `PROJECT_RECOMMENDATION`. Il tokenise le champ `query` ou le texte du projet. Le Reducer additionne les occurrences.

Resultat observe

```
airflow 4
boot 4
data 4
developer 5
engineering 4
flume 2
frontend 5
hadoop 2
hdfs 2
hive 4
learning 5
machine 5
python 5
react 5
security 4
spark 4
spring 4
sqoop 2
```

Commandes demo

```
powershell -ExecutionPolicy Bypass -File .\scripts\07_run_mapreduce.ps1\ndocker exec skillbridge-namenode hdfs dfs -ls
/data/skillbridge/processed/mapreduce/top_search_keywords\ndocker exec skillbridge-namenode hdfs dfs -cat
/data/skillbridge/processed/mapreduce/top_search_keywords/part-r-00000
```

Impact

Ce résultat permet d'expliquer quelles technologies ou intentions reviennent le plus dans les recherches et projets des utilisateurs.

11. HBase: course_stats

Le script Python `09_load_course_stats_hbase.py` combine les evenements, saved courses et progressions puis genere un script HBase. La table `course_stats` a deux familles: `meta` et `activity`.

courseid	title	clicks	saves	avg progress
1208	Análisis de Datos de Google Professional Certificate	0	1	80.0
4861	AWS: Amazon DynamoDB: Building NoSQL Database-Driven Applications	0	1	10.0
5064	HarvardX: Practical Improvement Science in Health Care: A Roadmap for Getting Results	0	1	10.0
5124	IBM: DevOps Basics for Everyone	0	1	80.0
5168	IBM: Technical Support Basics for Everyone	0	1	25.0
5322	SmithsonianX: Teaching Critical Thinking through Art with the National Gallery of Art	0	1	15.0
5443	UTAustinX: Linear Algebra - Foundations to Frontiers	0	1	15.0
5446	UWashingtonX: Building a Cybersecurity Toolkit	0	1	15.0
8494	Elements of AI	0	1	80.0
8497	Intelligenza Artificiale	0	1	10.0


Commandes demo

```
python .\scripts\09_load_course_stats_hbase.py
docker exec -i skillbridge-hbase /hbase/bin/hbase shell /opt/skillbridge/output/load_course_stats.hbase
echo "scan 'course_stats', {LIMIT => 5}" | docker exec -i skillbridge-hbase /hbase/bin/hbase shell -n
```

Pendant la generation du rapport, le scan direct HBase a retourne une erreur RegionServer `16020` connection refused . Les donnees HBase restent documentees via `bigdata-summary.json` et `load_course_stats.hbase` . Pour corriger: redemarrer `skillbridge-hbase` , attendre 60-90 secondes, puis relancer le scan.

12. Generate recommendations depuis le web

Figure 2 - Generate recommendations et trace Big Data



Quand l'utilisateur clique sur Generate recommendations, Spring Boot exécute le moteur rapide: chargement du projet, extraction de tokens, détection des skills, ranking des cours, sauvegarde du snapshot, puis écriture de l'événement `PROJECT_RECOMMENDATION`.

Le pipeline Big Data n'est pas bloquant: Flume absorbe ensuite l'événement, HDFS le stocke, Hive peut le compter, MapReduce peut en extraire les keywords.

13. Use cases et impact Big Data

Use case web	API backend	Donnee ecrite	Partie Big Data impactee	Commande de preuve
Search courses	GET /api/courses?q=...	COURSE_SEARCH dans events.log	Flume, HDFS, Hive, MapReduce	hdfs dfs -ls -R /data/skillbridge/raw/flume/events
Open course	POST /api/courses/{id}/click	COURSE_CLICK dans events.log	Flume, HDFS, HBase stats	Get-Content data/events/events.log -Tail 10
Save course	POST /api/saved-courses/{id}	saved_courses en PostgreSQL	Sqoop, Hive, HBase saves	select count(*) from saved_courses
Update progress	PUT /api/progress/{courseId}	course_progress	Sqoop, Hive, HBase avg_progress	select count(*) from course_progress
Create project	POST /api/projects	project_ideas + PROJECT_CREATED	Sqoop + Flume selon version	select count(*) from project_ideas
Generate recommendations	POST /api/projects/{id}/recommendations/generate	snapshot/results + PROJECT_RECOMMENDATION	Flume, HDFS, Hive, MapReduce	cat top_search_keywords/part-r-00000
Admin Big Data dashboard	GET /api/bigdata/status	lecture JSON/logs	Consomme output/*.json	Invoke-RestMethod /api/bigdata/status

14. Catalogue de commandes terminal pour soutenance

Partie	Commande	Ce que tu montres
Préparer les prérequis	powershell -ExecutionPolicy Bypass -File .\scripts\00_check_prereqs.ps1	Montre que Docker, Python et datasets existent.
Construire le catalogue	powershell -ExecutionPolicy Bypass -File .\scripts\16_run_catalog_build.ps1	Génère les CSV propres et catalog_build_report.json.
Voir les counts catalogue	Get-Content .\output\catalog\catalog_build_report.json	Prouve les 17k cours, 13k skills, 104k liens.
Démarrer le mirror	docker compose up -d postgres-mirror	Démarre la base relationnelle locale.
Compter les tables mirror	docker exec skillbridge-postgres-mirror psql -U skillbridge -d skillbridge -c "select count(*) from courses;"	Prouve le seed PostgreSQL.
Créer les dossiers HDFS	docker exec skillbridge-namenode bash /opt/skillbridge/scripts/03_create_hdfs_dirs.sh	Montre l'organisation raw/processed/export.
Lister HDFS	docker exec skillbridge-namenode hdfs dfs -ls -R /data/skillbridge	Prouve les fichiers importés et générés.
Relancer Sqoop	docker exec skillbridge-sqoop-client bash /opt/skillbridge/scripts/04_sqoop_import_mvp.sh	Montre l'import batch.
Démontrer Flume	Add-Content .\data\events\events.log '{"eventType":"COURSE_SEARCH","source":"demo","timestamp":"2026-05-20T00:00:00Z","query":"spring hive hadoop"}'	Ajoute un événement que Flume doit pousser dans HDFS.
Vérifier Flume dans HDFS	docker exec skillbridge-namenode hdfs dfs -ls -R /data/skillbridge/raw/flume/events	Montre les fichiers events.*.
Créer et interroger Hive	docker exec skillbridge-hive-server bash /opt/skillbridge/scripts/06_run_hive_queries.sh	Crée les tables externes et lance les requêtes demo.
Compter Hive	docker exec skillbridge-hive-server beeline -u jdbc:hive2://localhost:10000 --silent=true --showHeader=true --outputformat=table -e "use skillbridge_bigdata; select count(*) from hive_courses; select count(*) from hive_events;"	Montre les counts SQL.
Lancer MapReduce	powershell -ExecutionPolicy Bypass -File .\scripts\07_run_mapreduce.ps1	Compile et exécute TopSearchKeywordsJob.
Lire résultat MapReduce	docker exec skillbridge-namenode hdfs dfs -cat /data/skillbridge/processed/mapreduce/top_search_keywords/part-r-00000	Affiche keyword + count.
Matching Python	python .\scripts\08_match_project_skills.py	Génère project_skill_matches.csv.
Générer HBase script	python .\scripts\09_load_course_stats_hbase.py	Génère load_course_stats.hbase et bigdata-summary.json.
Charger HBase	docker exec -i skillbridge-hbase /hbase/bin/hbase shell /opt/skillbridge/output/load_course_stats.hbase	Crée/remplit course_stats.
Scanner HBase	echo "scan 'course_stats', {LIMIT => 5}" docker exec -i skillbridge-hbase /hbase/bin/hbase shell -n	Affiche les lignes HBase si le RegionServer est prêt.
Vérifier lien backend	powershell -ExecutionPolicy Bypass -File .\scripts\20_verify_app_bigdata_link.ps1 -BackendUrl http://localhost:8081 -MinimumCourses 1000	Prouve que Spring Boot voit le catalogue importé.
Pipeline complet	powershell -ExecutionPolicy Bypass -File .\scripts\18_run_full_terminal_lab.ps1 -Project "secure Spring Boot backend with JWT and PostgreSQL"	Démonstration intégrale pour soutenance.

15. Lecture des rapports generes

Rapport	Role
output/catalog/catalog_build_report.json	Audit des sources, counts finaux, distribution levels/categories/providers.
output/catalog/supabase_import_report.json	Dry-run ou apply Supabase, tables touchees, securite no global delete.
output/mirror_seed_report.json	Preuve que le mirror local est rempli.
output/project_skill_matches.csv	Associations projet -> skills detectees par Python.
output/bigdata-summary.json	Resume final lu par le dashboard admin.
output/recommendation_result.json	Derniere recommandation web/CLI avec trace pipeline.
output/app_bigdata_link_report.json	Preuve que Spring Boot voit le catalogue Big Data via API.

16. Conclusion technique

Le module Big Data de SkillBridge couvre les trois grandes familles attendues dans un projet Big Data pedagogique: ingestion batch avec Sqoop, ingestion streaming avec Flume, stockage distribue HDFS, SQL analytique avec Hive, traitement distribue Java avec MapReduce, et stockage serving avec HBase.

Son impact applicatif est concret: le catalogue massif nourrit Supabase et le frontend; les evenements web deviennent des donnees analytiques; les recommandations produisent une trace exploitable; l'admin peut expliquer le pipeline avec des commandes terminal et des rapports JSON.