

RAPPORT PDF BIG DATA

SkillBridge: Architecture, pipeline Big Data et fonctionnement par use case

Ce document explique le travail de chaque partie Big Data, le role de chaque conteneur Docker, l'installation des donnees, la liaison avec l'application web et le comportement du pipeline quand l'utilisateur clique sur Generate recommendations.

17 075

Cours visibles via le backend

13 647

Skills dans le catalogue

11


Services Docker Big Data

Regle d'architecture: le frontend React appelle seulement Spring Boot. Supabase reste la base applicative officielle. Hadoop, Hive, Flume, MapReduce et HBase restent terminal-first pour la demonstration Big Data.

1. Resume du projet

SkillBridge transforme une idee de projet en parcours d'apprentissage. L'utilisateur decrit ce qu'il veut construire. Le backend detecte les competences, classe les categories techniques et recommande des cours depuis un grand catalogue importe par le pipeline Big Data.

Figure 1 - Vue generale projet




Objectifs fonctionnels

- Authentifier l'utilisateur avec email/password, Google ou GitHub.
- Permettre la recherche dans un catalogue de cours volumineux.
- Generer des recommandations explicables a partir d'une idee de projet.
- Sauvegarder des cours et suivre la progression.
- Donner a l'admin une vue catalogue, utilisateurs, pipeline et analytics.

2. Architecture technique complete

Figure 2 - Architecture applicative et Big Data




Le backend n'exécute pas directement les jobs Hadoop pendant une requête utilisateur. Il écrit des événements et lit les rapports produits par le pipeline. Cette séparation rend l'application web rapide et garde la partie Big Data démontrable en terminal.

3. Installation et preparation des donnees

Le pipeline commence avant Hadoop: les datasets doivent etre disponibles localement.

Fichier	Role	Utilisation
archive (1).zip	Dataset final cleaned	Cours, plateformes, skills, ratings, etudiants.
archive.zip	All courses	Titres, descriptions, providers, URLs, reviews.
archive (2).zip	Coursera/edX riche	Descriptions, niveaux, langues, images, guided projects.

Figure 3 - Installation des donnees et construction catalogue




```
cd apps\bigdata
python -m pip install -r requirements.txt
python .\scripts\12_merge_and_enrich_catalog.py
```

Sorties principales: `output/catalog/unified_courses.csv`, `skills.csv`, `course_skills_staging.csv`, `catalog_build_report.json`.

4. Role de chaque conteneur Docker


Conteneur	Image	Role exact	Pourquoi il est necessaire
postgres-mirror	postgres:16	Base relationnelle locale remplie par les CSV du catalogue.	Sqoop importe depuis une base SQL stable sans toucher Supabase.
namenode	bde2020/hadoop-namenode	Metadata manager HDFS.	Gere l'arborescence HDFS et sait ou sont les blocs.
datanode	bde2020/hadoop-datanode	Stockage physique des blocs HDFS.	Permet de montrer le stockage distribue; scalable avec --scale datanode=2 .
resourcemanager	bde2020/hadoop-resourcemanager	Coordinateur YARN.	Planifie les traitements Hadoop/MapReduce.
nodemanager	bde2020/hadoop-nodemanager	Worker YARN.	Execute les containers de traitement sur le cluster.
sqoop-client	skillbridge-sqoop	Import batch PostgreSQL vers HDFS.	Charge les tables courses, skills, saved_courses, progress, etc.
flume-agent	skillbridge-flume	Ingestion streaming depuis events.log .	Capture les actions web en temps quasi reel vers HDFS.
hive-metastore-postgresql	bde2020/hive-metastore-postgresql	Base metadata Hive.	Stocke les definitions de tables Hive.
hive-metastore	bde2020/hive	Service metastore Hive.	Expose les schemas Hive au Hive Server.
hive-server	bde2020/hive	Endpoint SQL Beeline.	Permet d'interroger les donnees HDFS avec SQL.
hbase	harisekhon/hbase	Table key/value finale.	Stocke les stats par cours: clicks, saves, avg progress.

Figure 4 - Roles des conteneurs

5. Pipeline Big Data complet

Le script principal `18_run_full_terminal_lab.ps1` orchestre tout le laboratoire.

Figure 5 - Pipeline terminal complet




Etape	Travail effectuee	Sortie attendue
1	Fusion et nettoyage des ZIP.	CSV catalogue propres.
2	Dry-run ou upsert Supabase.	Rapport des tables touchees.
3	Seed du PostgreSQL mirror.	Tables locales remplies.
4	Sqoop importe les tables.	Fichiers HDFS raw/sqoop.
5	HDFS stocke batch et streaming.	Zones raw et processed.
6	Flume suit events.log.	events dans HDFS.
7	Hive cree tables externes.	Requetes SQL analytiques.
8	MapReduce compte keywords.	top_search_keywords.
9	Python detecte project skills.	project_skill_matches.csv.
10	HBase charge course_stats.	Stats rapides par course_id.
11	JSON final pour dashboard.	bigdata-summary.json.

6. Use case: Generate recommendations depuis le web

C'est le use case le plus important. L'utilisateur est dans la page detail d'un projet et clique sur **Generate recommendations**. Le pipeline web rapide s'exécute dans Spring Boot, puis un événement est écrit pour le pipeline Big Data.

Figure 6 - Generate recommendations web + Big Data



Details métier

- Le backend vérifie que le projet appartient à l'utilisateur connecté.
- Le texte est normalisé: minuscules, suppression ponctuation, tokens utiles.
- Les skills sont détectés par correspondance avec la table **skills**.
- Les cours candidats sont chargés depuis **courses** et **course_skills**.
- Le score combine titre, skills, catégorie et bonus popularité/Big Data.
- Le résultat est sauvegardé dans **recommendation_snapshots** et **recommendation_results**.
- L'événement **PROJECT_RECOMMENDATION** part dans **events.log**, puis Flume/HDFS.

7. Autres use cases et liaison Big Data

Recherche de cours

GET /api/courses?q=... lit le catalogue et écrit **COURSE_SEARCH** si une recherche existe.

Flume envoie cet événement dans HDFS. MapReduce calcule les top mots clés.

Clic sur un cours

POST /api/courses/{id}/click écrit **COURSE_CLICK**.

Les stats de clics peuvent alimenter Hive et HBase.

Sauvegarder un cours

POST /api/saved-courses/{courseId} remplit **saved_courses**.


Sqoop importe cette table vers HDFS; Hive calcule les cours les plus sauvegardés.

Progression

PUT /api/progress/{courseId} remplit **course_progress**.

Hive/HBase construisent **activity:avg_progress** dans **course_stats**.

Figure 7 - Evenements et tables par use case



8. Sorties, verification et demonstration

Resultat	Chemin ou commande	Ce qu'il prouve
Catalogue build report	<code>output/catalog/catalog_build_report.json</code>	Les datasets sont lus, nettoyes et dedupliques.
Mirror PostgreSQL	<code>select count(*) from courses;</code>	Le catalogue est pret pour Sqoop.
HDFS raw Sqoop	<code>hdfs dfs -ls /data/skillbridge/raw/sqoop/courses</code>	L'import batch fonctionne.
HDFS raw Flume	<code>hdfs dfs -ls -R /data/skillbridge/raw/flume/events</code>	Le streaming events.log fonctionne.
Hive	<code>select count(*) from hive_courses;</code>	Les fichiers HDFS sont queryables en SQL.
MapReduce	<code>top_search_keywords/part-r-00000</code>	Le traitement distribue produit des agregats.
HBase	<code>scan 'course_stats'</code>	Les stats finales sont disponibles par course_id.
Backend link	<code>20_verify_app_bigdata_link.ps1</code>	Spring Boot voit le catalogue enrichi.

Verification locale recente: backend live sur `http://localhost:8081`, 17 075 cours visibles, login admin OK, endpoint `/api/bigdata/status` OK, liaison app-catalogue OK.

Scenario de presentation conseille

1. Montrer les ZIP et expliquer pourquoi ils sont nettoyes.
2. Lancer ou afficher `12_merge_and_enrich_catalog.py`.
3. Montrer `catalog_build_report.json`.
4. Expliquer Supabase officiel vs PostgreSQL mirror local.
5. Montrer Sqoop vers HDFS.
6. Montrer Flume qui lit `events.log`.
7. Executer une requete Hive.
8. Afficher les top keywords MapReduce.
9. Scanner HBase `course_stats`.

10. Depuis le web, cliquer Generate recommendations et montrer l'événement dans Big Data status.

9. Conclusion

La partie Big Data de SkillBridge n'est pas seulement un ensemble de conteneurs: elle complete l'application web. Le catalogue massif est construit par Python, publie dans Supabase pour l'application, copie dans un PostgreSQL mirror pour Sqoop, stocke dans HDFS, analyse avec Hive et MapReduce, puis resume dans HBase et des fichiers JSON.

Quand l'utilisateur genere des recommandations, le backend donne une reponse rapide et explicable, puis laisse une trace evenementielle. Cette trace peut etre ingeree par Flume, analysee dans HDFS, et reutilisee dans les tableaux de bord admin. C'est la separation essentielle: le web reste rapide, le Big Data reste demonstrable, et les deux sont relies par les donnees.